Practice Case DataFlow

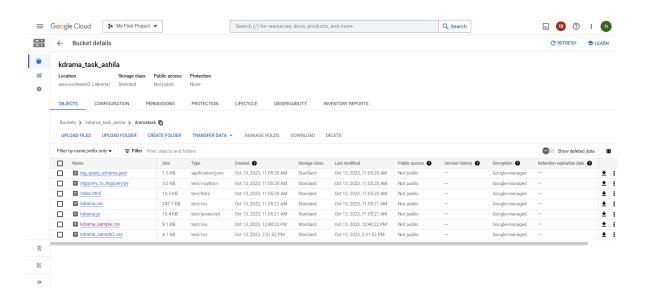
IYKRA DF11 Week 2

Group 3:

- Ashila Ghassani Astmara
- Rizka Virgianti
- Mentari Enggar Rizki
- Rizgullah Ramadhan Murdiansyah
- Yogi Fitriadi Rakhim

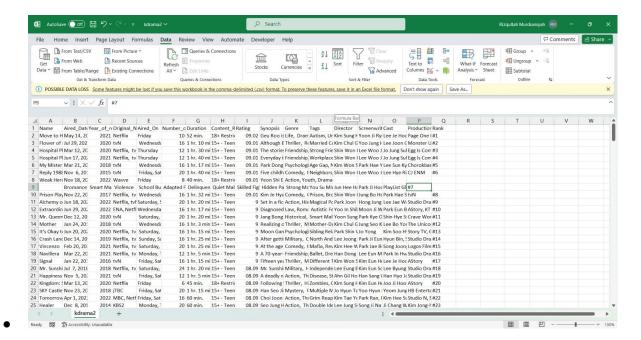
Step 1. The CSV data stored in the GCS bucket

- Pertama kita harus membuka google cloud storage untuk membuat GCS bucket dengan create.
- Buat bucket name, location type yang sesuai, storage class, control access, dan protect data.
- Buka bucket yang telah create, pilih upload file dan pilih raw data untuk dimasukan kedalam bucket.



Step 2: A BQ table from the CSV to BQ DataFlow pipeline

- Setelah memastikan raw data/ input file telah berhasil tersimpan di bucket gcp, kita dapat membuat kode file python untuk membuat dan menjalankan pipeline.
- File csv_gcs_to_bigquery.py merupakan file python untuk membuat dan menjalankan pipeline sebuah data csv ke dalam BigQuery. Kita bisa memodifikasi dalam file tersebut sesuai dengan proses transform data yang kita inginkan
- Pada data kdrama.csv memiliki beberapa kasus dimana kita perlu melakukan cleansing process. Contoh: terdapat row data yang split menjadi data baru. Hal ini dapat dilihat pada row 8 & 9 dibawah ini dengan film Weak Hero 1.

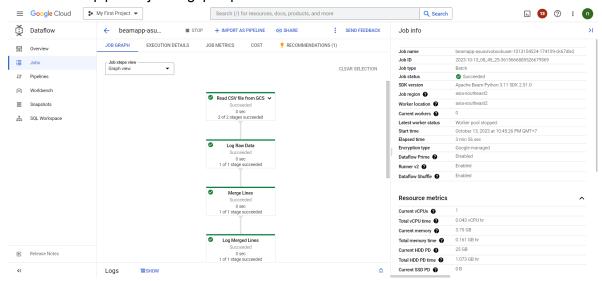


- Selain itu juga pada kolom Aired_Data, ada case dimana terdapat perbedaan format seperti 'Feb 14,2023' dan 'Jan 1,2023 - Jun 3, 2023'
- Oleh karena itu, kami melakukan beberapa modifikasi untuk dapat menyelesaikan transform data beberapa case diatas. Untuk case split kami menambahkan function MergeLine dan untuk case Aired_Date kami menambahkan beberapa conditional seperti dibawah ini:

```
#cleansing process tp merge every kdrama that split to a row
class MergeLines(beam.DoFn):
   def __init__(self, delimiter=','):
       self.buffered line = ''
       self.delimiter = delimiter
       self.num_columns = 17
       self._log = logging.getLogger('apache_beam.transforms.usercodetransformcontext')
   def process(self, line):
       # Continue appending lines to the buffer without adding extra spaces or stripping
        self.buffered line += line
       reader = csv.reader([self.buffered_line], delimiter=self.delimiter, quotechar='"')
       row = list(reader)[0]
        if len(row) == self.num_columns:
           result_line = self.buffered_line
            self.buffered line = '' # Clear the buffer for the next set of lines
           self. log.info(f"Merged Line: {result line}")
           yield result_line
```

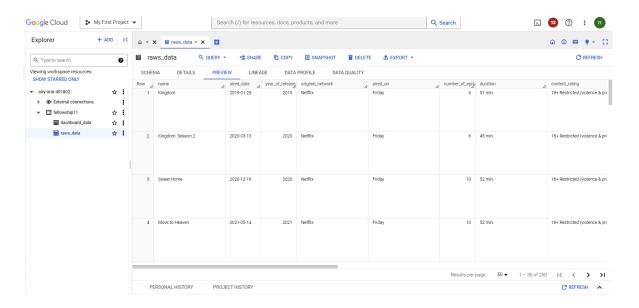
```
# Handle different 'Aired Date' formats
if "-" in values[1]: # Check if date range
| aired_date = datetime.strptime(values[1].split("-")[0].strip(), '%b %d, %Y').strftime('%Y-%m-%d')
else:
| aired_date = datetime.strptime(values[1], '%b %d, %Y').strftime('%Y-%m-%d')
self._log.info(f"Used Format for {values[1]} -> {aired_date}")
```

 Setelah itu, kita jalankan program csv_gcs_to_bigquery.py. Ketika berhasil, maka akan muncul pipeline job di gcp seperti berikut ini:



 Jika semua stage pipeline berhasil maka data akan muncul di table bigquery sesuai yang telah kita definisikan sebelumnya.

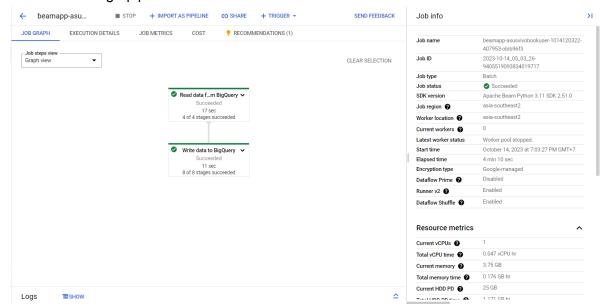
Berikut contoh output dari pipeline csv to bigguery:



Step 3. A BQ table from the BQ to BQ DataFlow pipeline

- Setelah memastikan raw data telah berhasil dibuat pada table BigQuery, kita dapat membuat kode file python baru untuk membuat dan menjalankan pipeline.
- File bigquery_to_bigquery.py merupakan file python untuk membuat dan menjalankan pipeline sebuah data dari sebuah table bigquery ke dalam table BigQuery yang lain. Kita bisa memodifikasi dalam file tersebut sesuai dengan output table yang kita inginkan
- Pada tugas ini , kita menginginkan scoring film berdasarkan ratingnya dan tahun rilisnya dan juga dibagi menjadi 3 kelompok yaitu Great, Excellent, dan Exceptional. Terakhir kita juga menghitung rata2 episode pada film yang dirilis setiap tahunnya.
- Oleh karena itu, kita membuat guery baru untuk memenuhi case diatas.

- Setelah itu, kita jalankan program bigquery_to_bigquery.py. Ketika berhasil, maka akan muncul pipeline job di gcp seperti berikut ini:
- Jika semua stage pipeline berhasil maka data akan muncul di table



bigquery sesuai yang telah kita definisikan sebelumnya.

 Jika semua stage pipeline berhasil maka data akan muncul di table bigquery sesuai yang telah kita definisikan sebelumnya.
 Berikut contoh output dari pipeline bigquery to bigquery:

